POLITECHNIKA GDAŃSKA
WYDZIAŁ ELEKTRONIKI, TELEKOMUNIKACJI I INFORMATYKI

Imię i nazwisko studenta: Rafał Kruszewski
Nr albumu: 198259
Poziom kształcenia: studia pierwszego stopnia
Forma studiów: stacjonarne
Międzywydziałowy kierunek studiów: Inżynieria biomedyczna
prowadzony przez: Wydział Elektroniki, Telekomunikacji i Informatyki; Wydział Chemiczny; Wydział Fizyki Technicznej i Matematyki Stosowanej
Profil: Informatyka w medycynie

PRACA DYPLOMOWA INŻYNIERSKA

Tytuł pracy w języku polskim: Aplikacja wspomagająca rozpoznawanie typów komórek krwi na podstawie obrazów mikroskopowych

Tytuł pracy w języku angielskim: An application supporting the recognition of blood cell types based on microscopic images

Opiekun pracy: dr inż. Anna Węsierska

POLITECHNIKA GDAŃSKA

<nazwa wydziału>

<Logo Wydziału>
(*max. wys. logo 15 mm*)

OŚWIADCZENIE dotyczące pracy dyplomowej zatytułowanej:
<„Tytuł”>

Imię i nazwisko studenta: <imię, nazwisko>
Data i miejsce urodzenia: <data, miejsce urodzenia>
Nr albumu: <nr albumu>
Wydział: <nazwa wydziału>
Kierunek: <nazwa kierunku> *

**dla kierunku międzywydziałowego stosuje się zapis:*
Międzywydziałowy kierunek studiów: <nazwa kierunku studiów>
prowadzony przez: <nazwa wydziału>; <nazwa wydziału>; <nazwa wydziału>

Poziom kształcenia: <studia pierwszego stopnia/studia drugiego stopnia>
Forma studiów: <stacjonarne/niestacjonarne>
Typ pracy: <praca dyplomowa inżynierska/praca dyplomowa inżynierski/praca dyplomowa licencjacka/praca dyplomowa magisterska>

Świadomy(a) odpowiedzialności karnej z tytułu naruszenia przepisów ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2019 r. poz. 1231, z późn. zm.) i konsekwencji dyscyplinarnych określonych w ustawie z dnia 20 lipca 2018 r. Prawo o szkolnictwie wyższym i nauce (t.j. Dz.U. z 2020 r. poz. 85, z późn. zm.),[1] a także odpowiedzialności cywilnoprawnej oświadczam, że przedkładana praca dyplomowa została opracowana przeze mnie samodzielnie.

Niniejsza praca dyplomowa nie była wcześniej podstawą żadnej innej urzędowej procedury związanej z nadaniem tytułu zawodowego.

Wszystkie informacje umieszczone w ww. pracy dyplomowej, uzyskane ze źródeł pisanych i elektronicznych, zostały udokumentowane w wykazie literatury odpowiednimi odnośnikami zgodnie z art. 34 ustawy o prawie autorskim i prawach pokrewnych.

<data, imię, nazwisko studenta>
Data i podpis – potwierdzenie w portalu uczelnianym MojaPG

OŚWIADCZENIE PRACY DYPLOMOWEJ
(strona nr 2 – numer strony nie może być widoczny)
Student, z portalu Moja PG, pobiera właściwą stronę z oświadczeniem

[1] Ustawa z dnia 20 lipca 2018 r. Prawo o szkolnictwie wyższym i nauce:

Art. 312. ust. 3. W przypadku podejrzenia popełnienia przez studenta czynu, o którym mowa w art. 287 ust. 2 pkt 1–5, rektor niezwłocznie poleca przeprowadzenie postępowania wyjaśniającego.

Art. 312. ust. 4. Jeżeli w wyniku postępowania wyjaśniającego zebrany materiał potwierdza popełnienie czynu, o którym mowa w ust. 5, rektor wstrzymuje postępowanie o nadanie tytułu zawodowego do czasu wydania orzeczenia przez komisję dyscyplinarną oraz składa zawiadomienie o podejrzeniu popełnienia przestępstwa.

STRESZCZENIE

Słowa kluczowe:

Dziedzina nauki i techniki, zgodnie z wymogami OECD:

ABSTRACT

Keywords :

Field of science and technology in accordance with OECD requirements:

WYKAZ WAŻNIEJSZYCH OZNACZEŃ I SKRÓTÓW

Terminologia użyta w pracy projektowej

ALL – ang. *Acute Lymphoblastic Leukemia* (ostra białaczka limfoblastyczna)
ALL-IDB – ang. *Acute Lymphoblastic Leukemia Image Database for Image Processing*
AML – ang. *Acute Myeloid Leukemia* (ostra białaczka szpikowa)
ANN – ang. *Artificial Neural Networks* (sztuczne sieci neuronowe)
BCCD – ang. *Blood Cell Count and Detection*
C-NMC – ang. *Classification of Normal versus Malignant Cells in B-ALL White Blood Cancer Microscopic Images*
CNN – ang. *Convolutional Neural Network* (konwolucyjna/splotowa sieć neuronowa)
DL – ang. *Deep Learning* (głębokie uczenie)
DT – ang. *Decision Trees* (drzewa decyzyjne)
GAN – ang. *Generative Adversarial Networks* (generatywne sieci przeciwstawne)
IoU – ang. *Intersection over Union* (miara optymalizacji ramek otaczających)
ISBI – ang. *International Symposium on Biomedical Imaging* (Międzynarodowe Sympozjum Obrazowania Biomedycznego)
KNN – ang. *K-Nearest Neighbors* (algorytm K-najbliższych sąsiadów)
LISC – ang. *Leukocyte Images for Segmentation and Classification*
ML – ang. *Machine Learning* (uczenie maszynowe)
MLP – ang. *Multi-Layer Perceptron* (klasyfikator perceptronu wielowarstwowego)
NBC – ang. *Naive Bayes Classifier* (naiwny klasyfikator Bayesa)
NNC – ang. *Nearest Neighbor Classifier* (klasyfikator najbliższego sąsiada)
OECD – ang. *Organisation for Economic Co-operation and Development* (Organizacja Współpracy Gospodarczej i Rozwoju)
PBC – ang. *Peripheral Blood Cells* (komórki krwi obwodowej)
PBF – ang. *Peripheral Blood Film* (badanie rozmazu krwi obwodowej)
R-CNN – ang. *Region-based Convolutional Neural Network*
RBC – ang. *Red Blood Cells* (czerwone krwinki / erytrocyty)
ReLU – ang. *Rectified Linear Unit* (liniowa funkcja aktywacji)
ResNet – ang. *Residual Network* (resztkowa sieć neuronowa)
RF – ang. *Random Forest* (algorytm lasów losowych)
RFE – ang. *Recursive Feature Elimination* (rekurencyjna eliminacja cech)
SAM – ang. *Segment Anything Model*
SESSA – ang. *Statistically Enhanced Salp Swarm Algorithm*
SVM – ang. *Support Vector Machine* (maszyny wektorów nośnych)
TTA – ang. *Test-Time Augmentation* (augmentacja podczas testowania)
VGG – ang. *Visual Geometry Group* (architektura sieci splotowej)

ViT – ang. *Vision Transformer* (transformator wizyjny)
WBC – ang. *White Blood Cells* (białe krwinki)
XAI – ang. *Explainable AI* (wyjaśnialna sztuczna inteligencja)
XGBoost – ang. *Extreme Gradient Boosting*
YOLO – ang. *You Only Look Once* (algorytm detekcji obiektów)

SPIS TREŚCI

Streszczenie **3**

Abstract **4**

Wykaz ważniejszych oznaczeń i skrótów **5**

Spis treści **8**

1. Wstęp **9**
1.1. Cel i założenia pracy 9
1.2. Struktura pracy 9

2. Wykorzystanie sztucznej inteligencji w klasyfikacji komórek krwi **11**
2.1. Wyzwania i mechanizmy w klasyfikacji medycznej 11
2.1.1. Metryki ewaluacyjne dla niezbalansowanych danych 11
2.2. Przegląd systematyczny metod głębokiego uczenia w diagnostyce białaczki . . . 12
2.3. Klasyfikacja podtypów białaczki z użyciem modeli hybrydowych 13
2.4. Porównanie sieci splotowych z architekturą Vision Transformer 15
2.5. Identyfikacja białych krwinek przy użyciu głębokich sieci splotowych 16
2.6. Przegląd metod uczenia maszynowego i głębokiego w identyfikacji białych krwinek 16
2.7. Wpływ przetwarzania wstępnego zdjęć na skuteczność klasyfikacji 17
2.8. Efektywna klasyfikacja białaczki poprzez selekcję głębokich cech algorytmem SES-SA 18
2.9. Wyzwanie WBCBench2026 w klasyfikacji białych krwinek 19
2.9.1. Uczenie hierarchiczne i modele fundacyjne 20
2.9.2. Zespoły małych klasyfikatorów do niezbalansowanych danych 21
2.9.3. Uczenie rozprzężone i normalizacja barwień 21

3. Analiza dostępnych baz danych oraz podobnych rozwiązań **22**
3.1. Baza danych Blood Cell images for Cancer detection 22
3.2. Baza danych Blood Cell Images (BCCD) 22
3.3. Baza danych C-NMC 2019 23
3.4. Baza danych Peripheral Blood Cell (PBC) 23
3.5. Baza danych Malaria Cell Images 24
3.6. Przegląd podobnych rozwiązań z portalu GitHub 25

4. Część eksperymentalna **28**

5. Materiały i metody **29**
5.1. Zbiór danych 29
5.2. Architektura zastosowanych modeli 29
5.3. Proces uczenia 29
5.4. Środowisko implementacyjne i narzędzia programistyczne 29
5.5. Metryki ewaluacyjne 29

6. Wyniki **30**

7. Dyskusja i podsumowanie **31**

Wykaz rysunków **35**

Wykaz tabel **36**

A. Dodatek A **37**

1. WSTĘP

Krew człowieka składa się z kilku podstawowych elementów morfotycznych, których prawidłowa budowa i proporcje są kluczowe dla zdrowia i prawidłowego działania organizmu. Elementy morfotyczne możemy podzielić na trzy główne grupy: erytrocyty (krwinki czerwone), trombocyty (płytki krwi) oraz leukocyty (białe krwinki), które dzielą się na zupełnie odrębne, wyspecjalizowane podtypy. Metodą umożliwiają ich ocenę jest badanie rozmazu krwi obwodowej (Peripheral Blood Film, PBF). Analiza obrazów mikroskopowych umożliwia wykwalifikowanej osobie ocenić morfologię poszczególnych komórek, co jest kluczowym elementem w rozpoznawaniu chorób nowotworowych. Jest to bardzo ważny aspekt, ponieważ nawet 70% decyzji klinicznych i diagnoz opiera się na medycynie laboratoryjnej [1].

Pomimo ogromnego znaczenia badania rozmazu krwi, tradycyjna, ręczna ocena mikroskopowa niesie ze sobą wiele problemów i ograniczeń. Głównym wyzwaniem jest to, że mikroskopia wymaga umiejętnego i systematycznego podejścia. Szybka ocena rozmazu może trwać nawet 3 minuty, a w przypadku nieprawidłowości koniecznie trzeba poświęcić więcej czasu na dokładniejszą analizę. Jej dokładność zależy od umiejętności i doświadczenia diagnosty, co niesie ze sobą ryzyko, że do oceny rozmazu wprowadzany jest element subiektywności oraz niedokładności spowodowanej zmęczeniem lub rutyną. W odpowiedzi na te trudności, wiele zespołów badawczych opracowało metody automatyzacji analizy rozmazu krwi w celu wykrywania konkretnych zaburzeń diagnostycznych. Pożądane jest, aby badania nad automatyzacją analizy rozmazów krwi koncentrowały się na rozwoju konkretnych metod radzących sobie z wahaniami oświetlenia i odcieni kolorów. Rozwiązaniem tych problemów okazało się cyfrowe przetwarzanie obrazów oraz stosowanie różnych algorytmów sztucznej inteligencji, w tym głębokich splotowych sieci neuronowych (CNN). Automatyzacja z wykorzystaniem technologii sztucznej inteligencji pozwala na bardzo szybkie zebranie danych diagnostycznych, gwarantując przy tym doskonałą powtarzalność. Dzięki tym rozwiązaniom decyzje kliniczne są silnie wspierane, eliminując błędy wynikające z czynnika ludzkiego [2].

1.1. Cel i założenia pracy

Celem pracy jest opracowanie, realizacja i walidacja oprogramowania wspomagającego rozpoznawanie typów komórek krwi na podstawie obrazów mikroskopowych. Projekt łączy wiedzę teoretyczną z zakresu komórek krwi z zaawansowanymi technikami ich rozpoznawania. W pierwszym etapie projektu przeprowadzony zostanie przegląd literatury naukowej dotyczącej wykorzystania sztucznej inteligencji w detekcji komórek krwi, gdzie wytłumaczono z jakich baz danych, jakiej architektury oraz jakie wyniki uzyskały poszczególne zespoły badawcze. Oprócz tego opisano dostępne bazy danych oraz podobne rozwiązania. Kolejnym etapem projektu będzie opracowanie modelu identyfikującego typy komórek krwi na podstawie obrazów mikroskopowych oraz jego integracja z aplikacją internetową umożliwiającą wygodne przesyłanie obrazów i analizę wyników.

1.2. Struktura pracy

Praca składa się z 7 rozdziałów, które opisują krok po kroku realizację projektu od wprowadzenia teoretycznego po analizę ostatecznych wyników i podsumowanie. Pierwszy rozdział zawiera wstęp teoretyczny, cel oraz założenia projektu. Rozdział drugi opisuje wykorzystanie sztucznej

inteligencji w klasyfikacji komórek krwi. Rozdział trzeci obejmuje przegląd dostępnych baz danych oraz podobnych rozwiązań. Rozdział czwarty prezentuje część eksperymentalną z wykorzystaniem otwartego kodu źródłowego. Rozdział piąty skupia się na metodologii badań. Rozdział szósty i siódmy zawierają wyniki i dyskusję.

2. WYKORZYSTANIE SZTUCZNEJ INTELIGENCJI W KLASYFIKACJI KOMÓREK KRWI

2.1. Wyzwania i mechanizmy w klasyfikacji medycznej

Przed analizą najnowszych rozwiązań związanych z detekcją białych krwinek, musimy zdefiniować kluczowe pojęcia i problemy, z którymi mierzą się w dzisiejszych czasach modele sztucznej inteligencji [3]. Jednym z głównych problemów w bazach danych jest rozkład długiego ogona (ang. long tail distribution). We krwi każdego człowieka występuje wiele komórek pospolitych, a bardzo mało komórek rzadkich. Zwykłe sieci neuronowe bardzo często mają problem z identyfikacją klas rzadkich (ang. rare-class identification), ponieważ w czasie treningu optymalizują się na podstawie klas dominujących.

Najczęstszym rozwiązaniem tego problemu jest zbalansowane próbkowanie klas (ang. class-balanced sampling), które polega na tym, aby losowane próbki z różnych klas pojawiały się tak samo często, bez względu na to, czy są rzadkie, czy powszechne. Z kolei, aby uodpornić sztuczną inteligencję na różnice między sprzętem w różnych szpitalach, stosuje się potok kontrolowanej degradacji (ang. control degradation pipeline), czyli specjalne pogarszanie jakości obrazów ze zbioru treningowego. Alternatywnym rozwiązaniem jest normalizacja barwień (ang. stain-normalization), która ujednolica kolory spod mikroskopu [4].

W uczeniu głębokim coraz częściej stosowane są modele fundacyjne (ang. foundation models), czyli wielkie, wstępnie wytrenowane na milionach obrazów sieci, które posiadają ogólną zdolność do wychwytywania podstawowych cech i potrzebują jedynie dotrenowania ich do konkretnego zadania [5]. W celu ułatwienia i przyspieszenia ich działania, stosuje się uczenie hierarchiczne (ang. hierarchical learning), w którym algorytm dzieli bazę danych na szersze, większe grupy, a dopiero później na mniejsze, bardziej precyzyjne podtypy. Kolejną zaawansowaną techniką jest uczenie rozprzężone (ang. decoupled learning), które polega na rozdzieleniu treningu na dwa etapy: ekstrakcję cech, a następnie trening klasyfikatora [4]. Inną bardzo skuteczną metodą poprawy wyników jest łączenie w zespoły (ang. ensembling), które polega na uśrednianiu wyników z wielu różnych, mniejszych klasyfikatorów oraz augmentacja podczas testowania (ang. Test-Time Augmentation, TTA), gdzie ostateczna decyzja podjęta przez model zależy od uśrednionych wyników dla wielu kopii jednego obrazu testowego, na którym zastosowano augmentację [6].

2.1.1. Metryki ewaluacyjne dla niezbalansowanych danych

Weryfikacja skuteczności modeli wykorzystywanych do różnych celów przy skrajnie niezbalansowanych danych wymaga zastosowania odpowiednich metryk. Standardowa dokładność (ang. accuracy) jest w takich sytuacjach niemiarodajna, ponieważ algorytm, który przypisywałby wszystkie badane dane wyłącznie do klasy dominującej, osiągnąłby sztucznie zawyżony wynik, całkowicie ignorując przy tym rzadkie stany patologiczne.

Podstawą rzetelnej oceny jest w tym przypadku macierz pomyłek (ang. confusion matrix), która obrazuje dokładnie rozłożenie błędnych predykcji ze względu na poszczególne kategorie i wskazuje, które typy danych są ze sobą najczęściej mylone. Jako główny wskaźnik wydajności w konkursach takich jak WBCBench2026 stosuje się metrykę Macro F1 [3]. Jej mechanizm polega na obliczeniu średniej harmonicznej precyzji i czułości oddzielnie dla każdej grupy, a dopiero na końcu obliczeniu ogólnej średniej arytmetycznej. Takie podejście jest bardzo ważne w medycy-

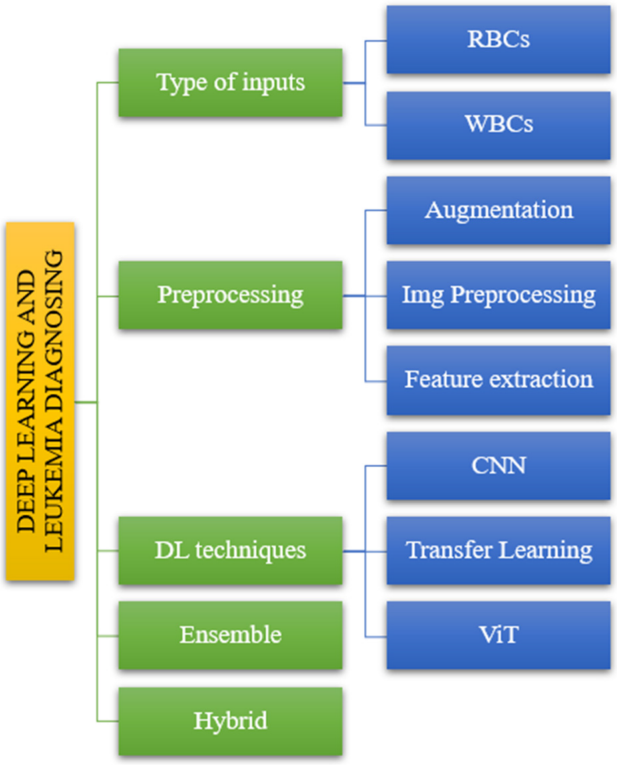
nie, ponieważ gwarantuje, że nawet najmniejsza, rzadka klasa ma równie wielki wpływ na ocenę końcową co większa, powszechna klasa.

2.2. Przegląd systematyczny metod głębokiego uczenia w diagnostyce białaczki

W celu dobrego zrozumienia użycia sztucznej inteligencji w identyfikacji typów komórek krwi warto spojrzeć na szczegółowe analizy. W 2025 roku Rakhmonalieva, Tagne Poupi i Kim opublikowali potężny przegląd [7], w którym przeanalizowali 30 artykułów z lat 2019-2023, w celu zbadania postępu w technikach uczenia głębokiego stosowanych do diagnozy białaczki na podstawie obrazów rozmazów krwi. Autorzy porównali różne podejścia, ich skuteczność, wady oraz zalety. Oprócz tego artykuł kładzie nacisk na aspekty etyczne oraz obszary, które do tej pory były słabo zbadane.

Z analizy wynika, że trzy najczęściej używanymi zbiorami danych do klasyfikacji białaczki są ALL-IDB, C-NMC 2019 oraz ASH Image Bank. ALL-IDB zawiera mikroskopowe obrazy krwinek z precyzyjnymi opiniami ekspertów, jednak liczba próbek jest bardzo mała, tak samo jak różnorodność warunków obrazowania. ASH Image Bank to publiczny, bogaty zbiór obrazów hematologicznych, często używany jako uzupełnienie. Niestety nie posiada standaryzacji obrazów oraz ma niespójne adnotacje, co utrudnia korzystanie. C-NMC 2019 to ogromny zbiór 15135 obrazów od 118 pacjentów z segmentowymi obrazami mikroskopowymi, zawierający różne, naturalne zakłócenia, co odwzorowuje naturalne warunki kliniczne w szpitalach, jednak poszczególne klasy mają różną ilość zdjęć, co utrudnia trening modeli. Jeszcze przed zastosowaniem algorytmów głębokiego uczenia, obrazy krwi poddawane są różnego rodzaju technikom przetwarzania wstępnego, co ma na celu poprawę jakości zdjęć, zwiększenie bazy treningowej czy ułatwienie ekstrakcji cech. Najczęściej stosowanymi metodami są augmentacja, konwersja przestrzeni barw, standaryzacja rozmiaru obrazów, segmentacja, progowanie, filtracja, normalizacja i ekstrakcja cech.

W przeglądzie wykorzystano kilka różnych modeli uczenia głębokiego, z których każdy ma swoje wady i zalety. W medycynie wciąż najczęściej stosowanymi modelami są konwolucyjne sieci neuronowe (CNN), które automatycznie uczą się hierarchicznych cech z obrazów. Jednak prawdziwym standardem powoli staje się Transfer learning, które wykorzystuje modele wstępnie wytrenowane na dużych zbiorach, a dopiero później są programowane do klasyfikacji białaczki. Kolejnym popularnym modelem jest Vision Transformer(ViT) wykorzystujący mechanizm uwagi, który pozwala na uchwycenie małych zależności w obrazie. Oprócz tego stosuje się modele hybrydowe czyli połączenie różnych architektur lub podejść i modele zespołowe, które łączą predykcję wielu modeli. Pełne zestawienie etapów diagnostyki oraz wykorzystywanych technik głębokiego uczenia podsumowano na Rysunku 2.1.



Rys. 2.1. Taksonomia metod głębokiego uczenia oraz etapów przetwarzania danych w diagnostyce białaczki. Źródło: [7]

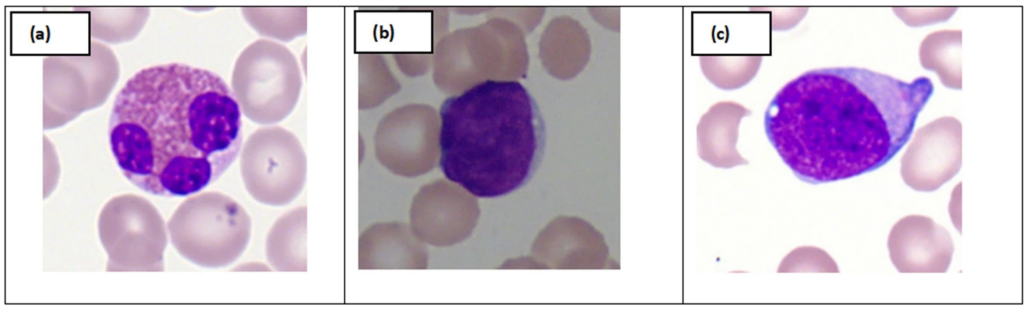
Mimo tego, że technologia postępuje, ogromnym problemem wciąż pozostaje brak odpowiedniej ilości zbiorów danych medycznych, co może prowadzić do przeuczenia się sieci. Kluczowym elementem w przyszłości medycyny i jednym z rozwiązań będzie rozwój technik wyjaśnialnej AI (XAI), co pozwoli badaczom lepiej zrozumieć, dlaczego dany model podjął określoną decyzję.

2.3. Klasyfikacja podtypów białaczki z użyciem modeli hybrydowych

W 2025 zespół badawczy, w skład którego wchodzili między innymi Sazzli Kasim i Sorayya Malek opracował nowy zautomatyzowany system do identyfikacji typów komórek krwi w celu zwiększenia dokładności diagnozy ostrej białaczki limfoblastycznej (ALL) oraz ostrej białaczki szpikowej (AML) [8]. Celem była zautomatyzowana klasyfikacja wieloklasowa na komórki zdrowe, limfoblasty oraz mieloblasty. Ich metoda wykorzystywała wstępnie wytrenowane modele głębokiego uczenia oraz klasyfikatory oparte na tradycyjnych modelach uczenia maszynowego, jak i głębokiego. Zastosowanie takiego podejścia hybrydowego miało na celu rozwiązanie problemu ograniczonej dostępności danych medycznych.

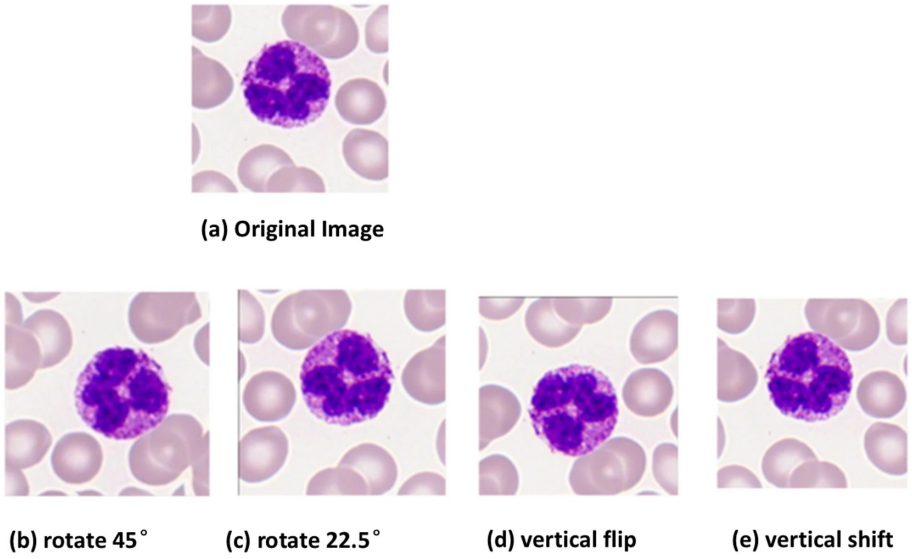
Bazy danych, z których korzystali autorzy artykułu do klasyfikacji ALL pochodziły z publicznie dostępnej bazy Acute Lymphoblastic Leukemia Image Database for Image Processing (ALL-IDB), która dzieli się na ALL-IDB1 oraz ALL-IDB2, które zawierają mikroskopowe obrazy próbek krwi. Do badania wybrali ALL-IDB2, ponieważ znajdują się w nim wstępnie wysegmentowane komórki. Z kolei dane dla AML pochodziły z bazy Munich AML Morphology Dataset, która zawiera obrazy rozmazów krwi od 100 pacjentów z rozpoznaniem AML oraz 100 przypadków bez zmian patologicznych. Razem wszystkie zbiory zawierały 390 obrazów, dla każdej klasy po 130 zdjęć, co zapewniło idealne zbalansowanie klas i zapobiegało faworyzowaniu którejkolwiek z nich przez model w procesie uczenia na przykład z powodu większej ilości danych wejściowych (Rysunek

2.2).



Rys. 2.2. Cechy morfologiczne: (a) zdrowych leukocytów, (b) limfoblastów i (c) mieloblastów, wykorzystywane do trenowania i oceny modelu. Źródło: [8]

W celu sztucznego zwiększania zbioru treningowego badacze zastosowali augmentację, obracając zdjęcia o 60 stopni i 90 stopni czy też odbijając je pionowo lub poziomo co świetnie obrazuje Rysunek 2.3.



Rys. 2.3. Dane rozszerzone przy użyciu technik augmentacji (rotacje i odbicia lustrzane) wykorzystane w procesie treningowym modelu. Źródło: [8]

Oprócz tego zastosowali segmentację semantyczną za pomocą sieci U-Net, która usuwała tło i wycinała same krwinki. Dzięki temu byli w stanie pozbyć się szumów i mogli skupić się na istotnych cechach, co znacząco ograniczyło ryzyko błędnej klasyfikacji na podstawie nieistotnych informacji znajdujących się na obrazach mikroskopowych.

Badacze zintegrowali ze sobą architektury CNN takie jak VGG16, InceptionV3 i ResNet50, które służyły do analizy i przetwarzania mikroskopowych obrazów rozmazów krwi z klasyfikatorami Random Forest (RF), Support Vector Machine (SVM), Extreme Gradient Boosting (XGBoost) oraz Multi-Layer Perceptron (MLP), które służyły do klasyfikacji podtypów białaczki. Na początku za pomocą segmentacji izolowano limfoblasty i mieloblasty od otoczenia i reszty składników komórkowych oraz ekstrahowano z nich cechy przy użyciu wytrenowanych CNN. Dopiero po tym za pomocą modeli klasyfikowano komórki wykorzystując wcześniej wspomniane klasyfikatory. Taki podział sprawił, że zaawansowane sieci splotowe działały jedynie jako potężne ekstraktory cech, a ostateczną decyzję podejmowały algorytmy znane ze swojej odporności na małe zbiory danych.

Największą dokładnością cechowała się kombinacja InceptionV3 wspólnie z SVM, która

osiągnęła ogólną dokładność na poziomie 88%, a tuż za nią znajdowała się kombinacja VGG16 z XGBoost, której dokładność wynosiła 87%. Najgorszą architekturą okazała się ResNet50, której najlepsze połączenie z RF wyniosło zaledwie 76%, co jest dużą różnicą w porównaniu z najlepszym wynikiem z architektur InceptionV3 i SVM. Jej zbyt głęboka architektura okazała się nieodpowiednia dla tak małego zbioru danych. Szczegółowa analiza macierzy pomyłek wykazała, że wszystkie modele miały największe problemy z prawidłowym rozpoznawaniem mieloblastów, ponieważ ich cechy morfologiczne bardzo pokrywały się z pozostałymi kategoriami komórek.

2.4. Porównanie sieci splotowych z architekturą Vision Transformer

Pod koniec 2023 roku Mohamad Abou Ali, Fadi Dornaika oraz Ignacio Arganda-Carreras opublikowali badanie, które porównuje skuteczność głębokich sieci neuronowych (CNN) i architektury Vision Transformer (ViT) w klasyfikowaniu białych krwinek [9]. Celem ich badań było zautomatyzowanie klasyfikacji typów białych krwinek na podstawie obrazów rozmazów krwi obwodowej, ponieważ aktualnie hematolodzy w szpitalach oglądają rozmazy pod mikroskopem, a ta metoda jest czasochłonna i podatna na błędy ludzkie. Nowatorstwo tego podejścia polegało na wykorzystaniu architektury ViT, która, w przeciwieństwie do tradycyjnych sieci CNN, korzysta z zaawansowanego mechanizmu samo-uwagi (ang. self-attention). Polega to na przetworzeniu całego obrazu jednocześnie i identyfikacji jego najważniejszych regionów. Dzięki temu dobrze rozpoznają kształty i kolory, co pozwala na skuteczniejszą naukę bardziej złożonych relacji.

Autorzy do badań wykorzystali dwie skrajnie różne bazy. Zbiór „peripheral blood cells” (PBC) zawierał 17092 obrazy ośmiu grup komórek krwi o wysokiej jakości i rozdzielczości oraz bez szumów. Do testów użyto zdjęć tylko 4 grup komórek, które pokrywały się z bazą „Blood Cell Count and Detection” (BCCD) zawierającą obrazy o niskiej jakości, z szumem i niską rozdzielczością. Dla bazy BCCD dodatkowo zastosowano augmentację w postaci obracania i ścinania obrazów. Ostatecznie zbalansowano zbiory w celu sprawdzenia zachowania obydwu modeli.

Badacze w swoich badaniach wykorzystali uczenie transferowe, zestawiając model Google ViT z 7 modelami splotowymi, wśród których znalazły się: DenseNet-169, DenseNet-201, InceptionResNet V2, ResNet-50 V2, ResNet-101 V2, ResNet-152 V2 i VGG-16. Dodatkowo autorzy użyli techniki Score-CAM do zwiększenia interpretowalności swoich modeli głębokiego uczenia poprzez wizualizację, na które obszary obrazu model zwraca największą uwagę podczas klasyfikacji.

Model Google ViT zdominował modele CNN. Na idealnej bazie PBC osiągnął perfekcyjny wynik 100% dokładności dla wszystkich 3 podzbiorów DS1, DS2, DS3. Z kolei na bardzo trudnej i zaszumionej bazie BCCD osiągnął wynik 88,36%, gdzie reszta modeli osiągała o wiele gorsze wyniki procentowe. Tak słaby wynik modeli CNN dla tej bazy był spowodowany przeuczeniem na skutek dużej ilości szumu i nadmiernej augmentacji zdjęć o słabej jakości. Oprócz tego, model Vision Transformer potrzebował o wiele więcej czasu na trenowanie i większej mocy obliczeniowej od klasycznych sieci splotowych. Było to spowodowane tym, że przy uczeniu transferowym w modelu ViT trenowane były wszystkie parametry sieci, a w modelach CNN zamrożono wagi warstw odpowiedzialnych za ekstrakcję cech i trenowano tylko klasyfikator. W tym przypadku architektura ViT była o wiele lepszym rozwiązaniem od klasycznych metod splotowych, ponieważ bardzo dobrze radzi sobie z brakami danych oraz szumami.

2.5. Identyfikacja białych krwinek przy użyciu głębokich sieci splotowych

Na początku 2024 roku Jinka Chandra Kiran i inni opublikowali pracę skupiającą się na klasyfikacji białych krwinek u pacjentów z białaczką [10]. Głównym celem była szybka automatyzacja diagnozy, ponieważ niewłaściwa identyfikacja typu białych krwinek (WBC) może być katastrofalna w skutkach i prowadzić do złego stanu pacjenta. W artykule autorzy skupili się na czterech typach, identyfikując, która krwinka spowodowała białaczkę.

Autorzy artykułu zebrali około 1200 zdjęć białych krwinek w 4 klasach ze strony internetowej Kaggle. Obrazy były zgromadzone z wielu różnych źródeł i przedstawiały morfologiczne i fenotypowe zmiany w białych krwinkach. Dane są bardzo wysokiej jakości, ponieważ zostały starannie oznakowane i skategoryzowane. Na każdym zdjęciu widać wyróżnioną niebieskim kolorem komórkę WBC wraz z niebieskim szumem, który był redukowany przy użyciu techniki zwanej metodologią wartości odstających. Wartościami odstającymi były elementy na obrazie, które wyraźnie odstawały od reszty w tym samym zbiorze. Mogą one wynikać z błędów pomiarowych, błędnie wprowadzonych danych lub prawdziwych wyników, które zwyczajnie odbiegają od normy. Po usunięciu szumu, obraz jest przycinany tak, żeby przesłać do analizy tylko obszar, na którym znajduje się wyróżniony na niebiesko fragment. Dzięki temu proces klasyfikacji mógł być o wiele dokładniejszy.

Badacze bezpośrednio zestawili ze sobą głęboką sieć splotową (CNN) z trzema klasycznymi algorytmami. K-Najbliższych Sąsiadów (KNN), który znajduje K obrazów najbardziej podobnych do nowego i na podstawie tego, do jakich grup one należą, decyduje, do której grupy należy nowy obraz. Maszyny Wektorów Nośnych (SVM) to model, w którym klasyfikuje się dane, szukając optymalnej granicy oddzielającej różne klasy na podstawie wyekstrahowanych cech. Sztuczne Sieci Neuronowe to model wzorowany na strukturze i funkcjonowaniu biologicznych neuronów znajdujących się między innymi w ludzkim mózgu, który uczy się rozpoznawać wzorce i klasyfikować dane poprzez połączenia wielu warstw neuronów przetwarzających informacje. Zespół badawczy zaprojektował na potrzeby badań autorską sieć splotową bazującą na warstwach z 32 filtrami oraz funkcją aktywacji ReLU odpowiedzialną za nieliniowość modelu. Całość uzupełnili o MaxPooling redukujący wymiarowość.

Największą dokładnością cechował się model CNN, który zdominował pozostałe osiągając dokładność na poziomie 93%, wyprzedzając SVM z wynikiem 87% oraz KNN z 82%. Zdecydowanie najgorzej wypadło ANN, których dokładność wyniosła zaledwie 67%. Badacze stwierdzili, że modele głębokich sieci neuronowych oferują o wiele większą dokładność w znajdowaniu skomplikowanych zależności mimo tego, że wymagają o wiele większej mocy obliczeniowej do trenowania i wnioskowania. Mimo wysokiej dokładności, po analizie macierzy pomyłek, autorzy zauważyli, że CNN miało największe problemy z rozróżnianiem eozynofili od neutrofili i doszli do wniosku, że w przyszłości modele będą potrzebowały większej ilości danych treningowych w celu lepszego działania w warunkach szpitalnych, gdzie dokładność i nieomylność jest kluczowa.

2.6. Przegląd metod uczenia maszynowego i głębokiego w identyfikacji białych krwinek

W dzisiejszych czasach modele uczenia maszynowego (ML) i głębokiego uczenia (DL) są coraz częściej wykorzystywane w medycynie, szczególnie do analizy obrazów medycznych. Oba te podejścia pomagają badaczom, lekarzom i diagnostom w codziennej pracy poprzez zwiększenie dokładności klasyfikacji w diagnozowaniu i leczeniu różnego rodzaju chorób. Problem, który zauważyli autorzy artykułu, Rabia Asghar, Sanjay Kumar, Arslan Shaukat i Paul Hynds polegał na

tym, że do tamtej pory inni badacze je testowali, ale nikt nie przeprowadził globalnego przeglądy tych technik do identyfikacji białych krwinek na obrazach rozmazów krwi, co może być bardzo przydatne w przyszłości do identyfikacji wielu groźnych chorób związanych z różnymi patologiami i odchyleniami od standardów [11]. W związku z tym autorzy chcieli przeprowadzić dokładną analizę i porównanie obydwu metod, koncentrując się na identyfikacji pięciu typów białych krwinek i przybliżeniu przyszłych problemów i zalet tych rozwiązań.

W swojej analizie, autorzy zauważyli ogromną rozbieżność w ilości danych wejściowych z różnych baz danych. Przeanalizowali 27 baz danych pochodzących między innymi z serwisów takich jak Kaggle, ALL-IDB2, BCCD czy LISC. Liczba zdjęć w poszczególnych zbiorach wahała się od zaledwie 21 do aż 92 800 fotografii. Z powodu małej liczby zdjęć mikroskopowych niektórzy badacze musieli trenować swoje modele na bardzo małej ilości danych wejściowych, co drastycznie pogarsza ich dokładność i skuteczność. Zwykła augmentacja to zdecydowanie za mało: zwykłe obracanie i odbicia lustrzane są zbyt trywialne dla nowoczesnych CNN, które szybko rozpoznają zastosowane przekształcenia. Z tego powodu inżynierowie zaczęli stosować Generatywne Sieci Przeciwstawne (GAN), które samodzielnie generują całkowicie nowe, sztuczne zdjęcia krwinek, które są na tyle dokładne i szczegółowe, że są w stanie oszukać nawet specjalistów.

Badacze w swojej analizie zestawili wyniki różnych modeli przetestowanych przez innych autorów, które obejmowały drzewa decyzyjne (DT), algorytm K-średnich, naiwny klasyfikator Bayesa (NBC), klasyfikator najbliższego sąsiada (NNC), maszyny wektorów nośnych (SVM), sztuczne sieci neuronowe (ANN) oraz techniki progowania. Początkowo do identyfikacji WBC wykorzystywano głównie konwencjonalne uczenie maszynowe, ale w ostatnich latach zauważono duży wzrost w wykorzystaniu do tego tematu uczenia głębokiego. W szczególności stosowane były konwolucyjne sieci neuronowe, które były najdokładniejsze i cechowały się największą wydajnością.

Konwencjonalne modele uczenia maszynowego osiągały do 99% dokładności, a ich dokładność spadała wraz ze zmniejszaniem się ilości danych wejściowych ze zbiorów zdjęć. Modele uczenia głębokiego cechowały się większą dokładnością wraz ze wzrostem wielkości zbiorów. Największą skutecznością cieszyło się wykorzystanie Konwolucyjnej Sieci Generatywnej z dokładnością na poziomie 99,9% na zbiorze z Catholic University of Korea. Tuż za nim znalazło się rozwiązanie wykorzystujące konwolucyjne sieci neuronowe z dokładnością 98,51%. Z tego wynika, że w przyszłości CNN oraz GAN powinny być coraz częściej wykorzystywane w medycynie i innych dziedzinach życia, ponieważ cechują się prawie idealną dokładnością, co jest kluczowe w rozwoju.

2.7. Wpływ przetwarzania wstępnego zdjęć na skuteczność klasyfikacji

Innym ważnym aspektem w wykrywaniu groźnych chorób jest analiza obrazów medycznych w celu segmentacji i klasyfikacji leukocytów. Celem zespołu badawczego pod kierownictwem Vasali Anand było stworzenie systemu do automatycznej segmentacji i klasyfikacji monocytów, limfocytów, eozynofilów i neutrofilów [12]. Autorzy dążyli do wyeliminowania wad tradycyjnej diagnostyki hematologicznej, która jest pracochłonna, czasochłonna i jest uzależniona od subiektywnej decyzji specjalisty, który nie jest nieomylny. Badacze stwierdzili, że uzyskanie wysokiej wydajności modelu głębokiego uczenia wymaga precyzyjnego przygotowania danych wejściowych.

Do swoich eksperymentów użyli zbiór danych z serwisu Kaggle, który zawierał 12 444 zdjęcia mikroskopowe próbek krwi. Każda grupa zawierała średnio ponad 3100, a dane zostały podzielone w proporcji 80:20 na zbiór przeznaczony do treningu (9955 obrazów) oraz zbiór prze-

znaczony do testów (2489 obrazów). Zanim jednak poddali zdjęcia uczeniu, autorzy zastosowali szereg czynności służących do przetwarzania wstępnego. Proces ten obejmował segmentację obrazu przy użyciu metody progowania Otsu do wygenerowania masek tła, erytrocytów oraz leukocytów. Dodatkowo, zastosowano proces erozji, a następnie dylatacji w celu usunięcia drobnych szumów oraz izolację i kadrowanie w celu wyrzucenia kompletnie zbędnego tła i sąsiadujących czerwonych krwinek. Kolejnym kluczowym elementem przetwarzania wstępnego była augmentacja w postaci regulacji jasności i kontrastu, stosowanie lustrzanych odbić oraz losowe ścianie co miało zapobiec przeuczaniu się modelu.

Po wykonaniu tych wszystkich kroków, dane zasiliły autorską głęboką sieć splotową składającą się z czterech bloków konwolucyjnych z jedenastoma wastwami splotowymi, warstw normalizacji wsadowej (Batch Normalization), aktywacji ReLU oraz warstw dropout, które zapobiegają nadmiernemu dopasowaniu.

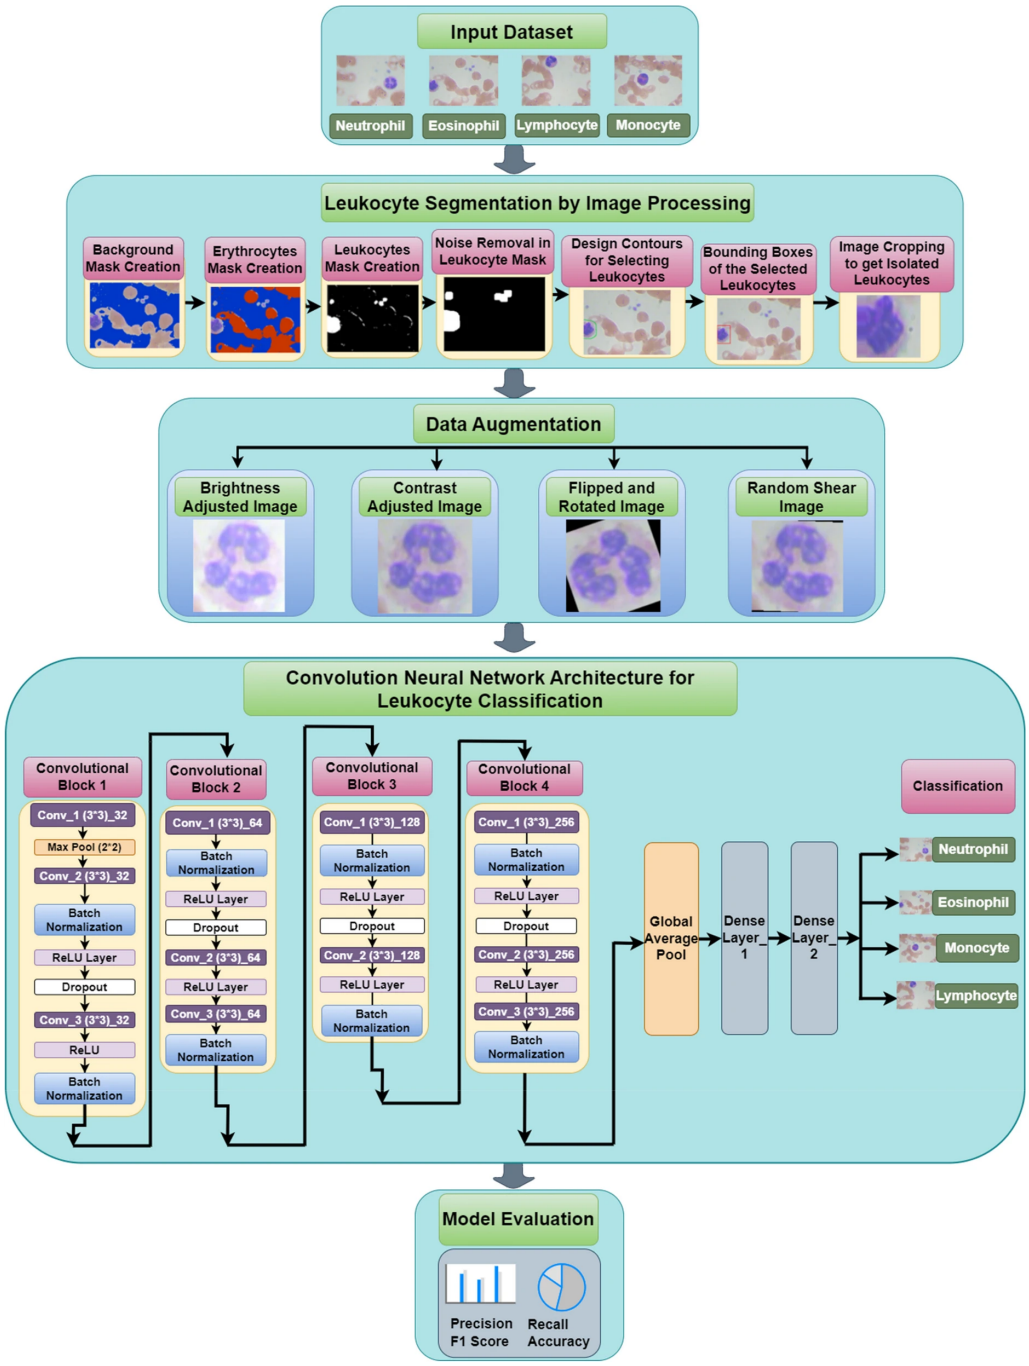
Teza autorów artykułu była bardzo trafna, ponieważ model CNN, działający na oryginalnych, nieprzerobionych obrazach uzyskał zaledwie 79% dokładności. Z kolei po zastosowaniu szeregu działań przetwarzania wstępnego, metoda uzyskała dokładność na poziomie 97,98% oraz precyzję na poziomie 97,97%. To badanie jest idealnym potwierdzeniem, że przetwarzanie zdjęć wejściowych jest niezbędnym elementem dzisiejszych systemów wspomagających decyzję medyczne.

2.8. Efektywna klasyfikacja białaczki poprzez selekcję głębokich cech algorytmem SESSA

Ahmed T. Sahlol z resztą zespołu badawczego chcieli opracować wydajny system hybrydowy do klasyfikacji obrazów białaczki, który łączy wysoką dokładność klasyfikacji z obniżonym kosztem obliczeniowym [13]. Autorzy zwrócili szczególną uwagę na to, że mimo popularności CNN, ich trenowanie wymaga ogromnych zasobów i zbiorów danych, do których jest ograniczony dostęp, a są one kluczowe. Rozwiązaniem tego problemu miało być zastosowanie uczenia transferowego (transfer learning) w celu ekstrakcji cech.

Zespół badawczy skorzystał z dwóch publicznych zbiorów danych odpowiadających białaczce WBC: ALL-IDB2 składającego się z 260 obrazów, po 130 komórek łagodnych i złośliwych limfoblastów oraz C-NMC, składająca się z 10 661 obrazów pochodzących od 76 pacjentów, 7 272 komórek złośliwych i 3 389 zdrowych komórek.

Ich badanie polegało na połączeniu głębokiego uczenia z algorytmem bioinspirowanym. Wykorzystali architekturę VGGNet, a dokładniej VGG19, która była wstępnie wytrenowana na zbiorze ImageNet. Sieć ta służyła do automatycznego ekstrahowania cech. Do usunięcia niepotrzebnych, powtarzających się i zaszumionych danych użyli algorytmu SESSA (Statistically Enhanced Salp Swarm Algorithm). SESSA wykorzystuje operacje statystyczne, jak Chi-kwadrat do eliminacji skorelowanych cech, rekurencyjna eliminację cech (RFE) oraz klasyfikatory drzewiaste w celu usprawnienia podstawowego algorytmu roju salp. Pełny schemat blokowy opisanej architektury, uwzględniający podział na etap ekstrakcji cech oraz ich wielostopniowej selekcji, przedstawiono na Rysunku 2.4.



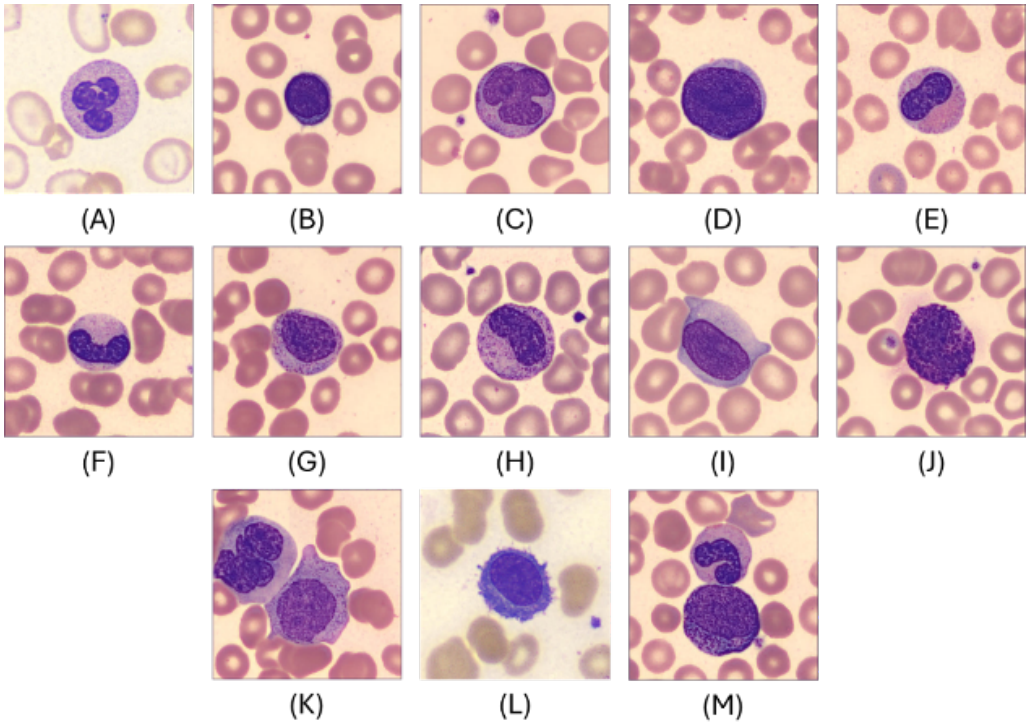
Rys. 2.4. Schemat blokowy hybrydowego systemu klasyfikacji obrazów białaczki łączącego sieć VGG19 z algorytmem optymalizacji SESSA. Źródło: [13]

na zbiorze ALL-IDB2 model osiągnął dokładność klasyfikacji na poziomie 96,11%, wyprzedzając pod tym względem inne modele architektury CNN oraz podstawowy model VGG19. Z kolei na trudniejszym zbiorze C-NMC model uzyskał dokładność na poziomie zaledwie 83,3%. Autorzy udowodnili, że selekcja cech nie tylko oszczędza czas i pamięć, ale paradoksalnie poprawia też skuteczność klasyfikacji dzięki usuwaniu zbędnych informacji z obrazów.

2.9. Wyzwanie WBCBench2026 w klasyfikacji białych krwinek

W 2026 roku podczas konferencji ISBI zorganizowano konkurs WBCBench2026, którego celem była weryfikacja algorytmów w wymagających i rzeczywistych warunkach klinicznych [3]. Orga-

nizatorzy wyzwania narzucili uczestnikom bazę danych składającą się z 55 tysięcy obrazów, podzielonych na 13 klas morfologicznych. Głównym wyzwaniem dla zespołów konkursowych były symulowane rozbieżności sprzętowe, nazywane przesunięciem domenowym, czego powodem było pochodzenie zdjęć z różnych aparatów. Oprócz tego wprowadzono celowe zjawisko nierównomiernej liczebności poszczególnych klas, czyli zjawisko długiego ogona. Najbardziej powszechna klasa miała zasoby w wysokości dziesiątek tysięcy zdjęć mikroskopowych, a najrzadsza klasa miała ograniczoną liczbę zdjęć, co miało odwzorować rozkład krwinek w ludzkim ciele. Z tego powodu odrzucono klasyczną dokładność, a zastąpiono ją rzetelniejszą metryką Macro F1. Przykładowe obrazy wszystkich trzynastu klas typów komórek krwi, z którymi mierzyli się uczestnicy konkursu, zostały przedstawione na rysunku 2.5.



Rys. 2.5. Przykładowe obrazy 13 klas białych krwinek z odgórnie narzuconego zbioru danych w wyzwaniu WBCBench2026: (A) neutrofil segmentowany, (B) limfocyt, (C) monocyt, (D) komórka blastyczna, (E) eozynofil, (F) neutrofil pałeczkowaty, (G) mielocyt, (H) metamielocyt, (I) limfocyt atypowy, (J) bazofil, (K) promielocyt, (L) komórka plazmatyczna, (M) prolimfocyt [3].

2.9.1. Uczenie hierarchiczne i modele fundacyjne

Najwyższą skuteczność na narzuconym zbiorze 55 tysięcy zdjęć w konkursie WBCBench2026 uzyskał zespół badawczy Team FDVTS_WBC [5]. Członkowie tego zespołu, zamiast klasycznej augmentacji obrazów, użyli integracji potężnych modeli fundacyjnych, takich jak DinoBloom oraz DINOv3. W celu dostosowania sieci do specyfiki obrazów krwi, autorzy musieli zastosować i połączyć je z algorytmami pseudo-etykietowania. Dzięki temu mechanizmowi, system automatycznie ekstrahował dodatkową wiedzę z nieoznaczonych zbiorów testowych bazy danych konkursu.

Największym problemem dla grupy badawczej okazał się znaczący deficyt obrazów dla klas mniejszościowych, ponieważ brakowało zasobów do poprawnej optymalizacji wag. Zespół rozwiązał ten problem w innowacyjny sposób, wdrażając dedykowany system głosowania binarnego, który był wspierany przez metodę dopasowywania wzorców. Celem tej techniki jest wyliczenie

odległości cech nowej próbki względem zakodowanych zasobów rzadkiej klasy. To rozwiązanie zagwarantowało zespołowi pierwsze miejsce w konkursie z rekordowym wynikiem Macro F1 na poziomie 0,777.

2.9.2. Zespoły małych klasyfikatorów do niezbalansowanych danych

Zupełnie alternatywną metodę zaproponował inny zespół, pod kierownictwem Siddhartha Srivastavy i innych [6]. Autorzy zauważyli, że współczesne sieci stają się zbyt rozbudowane sprzętowo, dlatego odrzucili koncepcję pojedynczej, ciężkiej architektury na rzecz lżejszego podejścia zespołowego. Ich struktura łączyła predykcje z trzech znacznie mniejszych, zoptymalizowanych modeli: SwinV2-Tiny, ConvNeXT-V2-Tiny oraz DinoBloom-Small.

W celu zmniejszenia problemu braku zdjęć dla klas rzadkich, autorzy zdecydowali się sztucznie powiększyć bazę danych o dodatkowe 13 tysięcy próbek ze źródeł publicznych. Rozbudowali również metodę o etap zaawansowanego przetwarzania wstępnego na oryginalnych zdjęciach z WBCBench2026. Zaimplementowali również adaptacyjne filtrowanie szumów z wykorzystaniem algorytmu Non-local means, który miał na celu wygładzenie tła bez utraty szczegółów krawędzi komórek. Dzięki temu sposobowi zespołowi udało się uzyskać ostateczny wynik Macro F1 na poziomie 0,6772 na końcowym zbiorze testowym przy jednoczesnej minimalizacji obciążenia na kartach graficznych. Pełna implementacja oraz kod źródłowy całego algorytmu zostały udostępnione przez autorów w otwartym repozytorium [14].

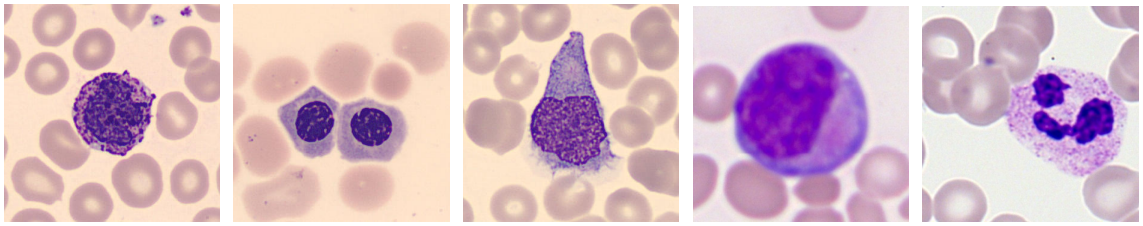
2.9.3. Uczenie rozprzężone i normalizacja barwień

Kolejną architekturę na potrzeby wyzwania WBCBench2026 opracowała grupa badawcza o nazwie Team AIO-MHIL [4]. Zespół pod przewodnictwem Luu Le zastosował normalizację Macenko, która ujednolica barwy obrazów medycznych, w celu likwidacji różnic w jakości i kolorystyce zdjęć z różnych aparatów. Proces uczenia rozdzielili na dwa etapy. Pierwszym z nich była nauka odpowiedniej reprezentacji cech, wykorzystując losowe próbkowanie danych. Drugim etapem było rebalansowanie klasyfikatora, gdzie zamrażano wagi i trenowano jedynie klasyfikator. Podczas testowania system korzystał z augmentacji generującej osiem wariantów każdego zdjęcia, a ostateczny wynik był uśredniany na podstawie trzech modeli: ResNet50, ResNet152 i Swin Transformer. Rozwiązanie to pozwoliło badaczom uzyskać bardzo wysoki wynik Macro F1 na poziomie 0,742. Ponadto kompletne materiały programistyczne i skrypty trenujące tego rozwiązania udostępniono w publicznym repozytorium [15].

3. ANALIZA DOSTĘPNYCH BAZ DANYCH ORAZ PODOBNYCH ROZWIĄZAŃ

3.1. Baza danych Blood Cell images for Cancer detection

Baza danych ”Blood Cell images for Cancer detection” [16] to publiczna baza danych udostępniona w serwisie Kaggle w 2025 roku. Baza zdjęć zawiera obrazy rozmazów krwi do wizji komputerowej oraz analizy obrazów medycznych w celu pomocy w wykrywaniu nowotworu krwi. Zasób zawiera 5000 zdjęć, po 1000 dla każdej z 5 klas: bazofile (basophil), erytroblasty (erythroblast), monocyty (monocyte), mieloblasty (myeloblast) oraz neutrofile segmentowane (seg_neutrophil). Obrazy są zapisane w formacie jpg, a ich rozdzielczość waha się w przedziale od 360x363 do 400x400 pikseli. Autorzy nie udostępnili danych takich jak ilość, wiek czy płeć pacjentów, jednak wysoka jakość zdjęć i równa ilość obrazów w każdej z klas jest świetnym rozwiązaniem do trenowania modeli uczenia maszynowego w celu wykrywania chorób krwi.

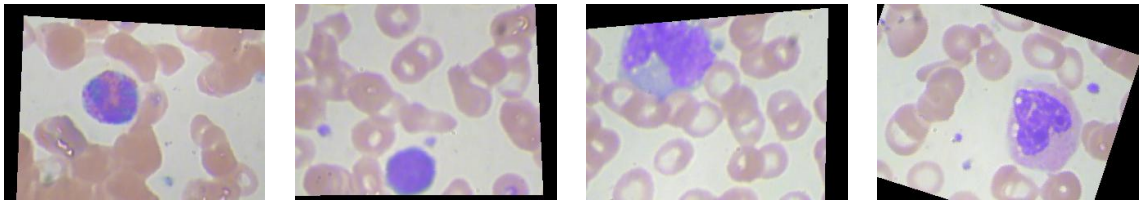


(a) Bazofil **(b)** Erytroblast **(c)** Monocyt **(d)** Mieloblast **(e)** Neutrofil

Rys. 3.1. Przykładowe obrazy komórek z bazy danych z podziałem na pięć klas. Źródło: [16]

3.2. Baza danych Blood Cell Images (BCCD)

Kolejną bazą danych jest ”Blood Cell Images” [17] z serwisu Kaggle, która jest rozszerzeniem ogólnodostępnego repozytorium BCCD [18]. Zbiór powstał ze względu na zbyt małą liczbę obrazów do treningu modeli sztucznej inteligencji. Oryginalna baza danych zawierała jedynie 410 zdjęć mikroskopowych z adnotacjami w postaci ramek ograniczających. Autor wersji z serwisu Kaggle poddał ten zbiór agresywnej augmentacji danych i rozszerzył zbiór do 12500 obrazów w formacie JPG. Dane zostały równomiernie podzielone na cztery klasy morfologiczne po około 3000 obrazów: eozynofile (eosinophil), limfocyty (lymphocyte), monocyty (monocyte) oraz neutrofile (neutrophil). Tak posortowane dane sprzyjają wykorzystywaniu tej bazy danych do trenowania głębokich sieci splotowych.

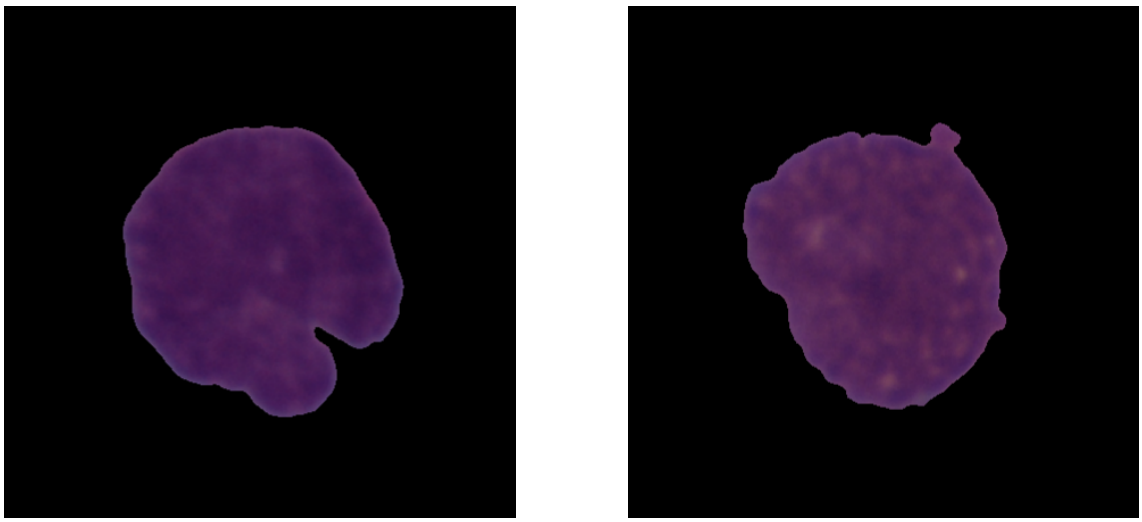


(a) Eozynofil **(b)** Limfocyt **(c)** Monocyt **(d)** Neutrofil

Rys. 3.2. Przykładowe obrazy komórek ze zbioru *Blood Cell Images* (BCCD) reprezentujące cztery różne klasy morfologiczne białych krwinek: eozynofil, limfocyt, monocyt oraz neutrofil. Źródło:[17]

3.3. Baza danych C-NMC 2019

Kolejnym zbiorem danych jest baza ”C-NMC 2019 Dataset” [19]udostępniona w serwisie Kaggle. W przeciwieństwie do poprzednich zbiorów, gdzie zdjęcia mikroskopowe były klasyfikowane do odpowiednich grup, baza ta została podzielona na komórki prawidłowe oraz patologiczne. Zbiór charakteryzuje się wysoką wiarygodnością, ponieważ dane z rozmazów krwi zostały zebrane od 118 różnych pacjentów. Zbiór został podzielony na treningowy obejmujący 10661 obrazów, w tym 3389 zdrowych komórek oraz 7272 komórek nowotworowych oraz zbiory testowe zawierające około 4400 obrazów. Taki podział klas oraz ilość danych jest idealną opcją do weryfikacji głębokich sieci splotowych obserwacji zmian nowotworowych.

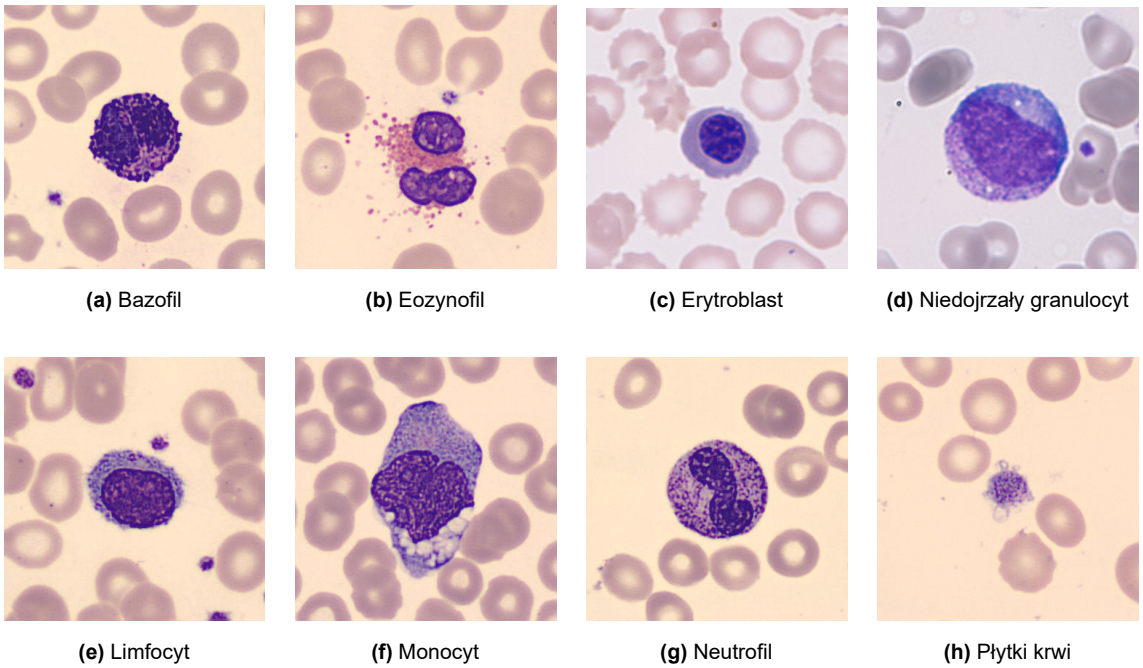


(a) Komórka nowotworowa **(b)** Komórka prawidłowa

Rys. 3.3. Porównanie próbek z bazy C-NMC 2019. Źródło: [19]

3.4. Baza danych Peripheral Blood Cell (PBC)

Baza danych Peripheral Blood Cell (PBC) [20] została udostępniona na platformie Mendeley Data oraz opisana w literaturze autorstwa A. Avecedo i innych [21]. Jest to bardzo rozbudowany zbiór zdjęć do klasyfikacji krwinek. Zawiera 17092 obrazów w jednolitym rozmiarze 360x363 pikseli w formacie JPG. Autorzy nie sprecyzowali od ilu pacjentów dane zostały zebrane, jednak zapewniają, że krew została pobrana tylko i wyłącznie od osób zdrowych w momencie przeprowadzania badania. Zbior dzieli się na 8 precyzyjnych klas morfologicznych: bazofile, eazynofile, erytroblasty, niedojrzałe granulocyty, limfocyty, monocyty, neutrofile oraz płytki krwi.



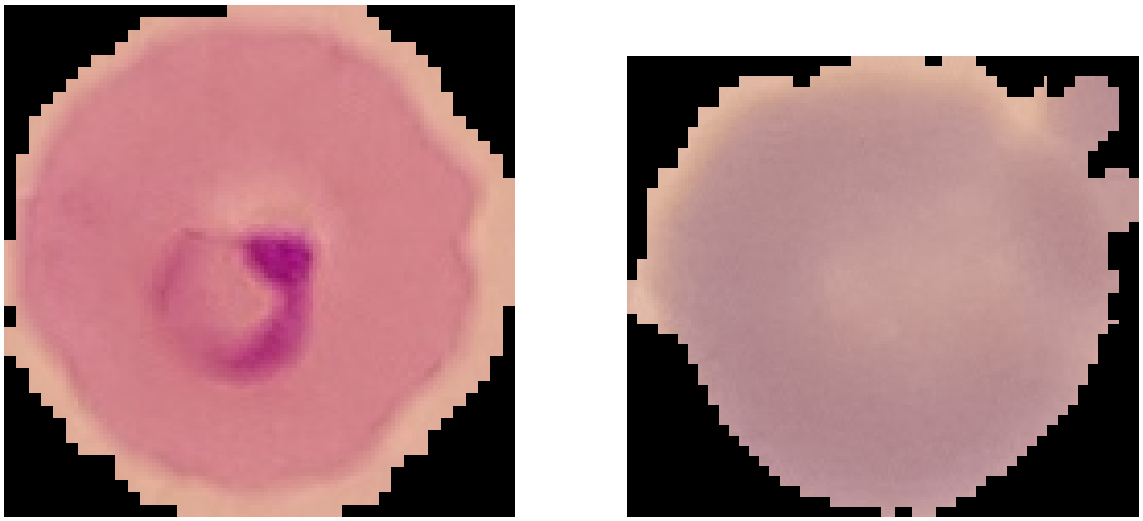
(a) Bazofil **(b)** Eozynofil **(c)** Erytroblast **(d)** Niedojrzały granulocyt

(e) Limfocyt **(f)** Monocyt **(g)** Neutrofil **(h)** Płytki krwi

Rys. 3.4. Przykładowe obrazy ośmiu klas morfologicznych krwinek ze zbioru *Peripheral Blood Cell* (PBC). Źródło: [20, 21]

3.5. Baza danych Malaria Cell Images

Kolejną bazą danych jest ”Malaria Cell Images Dataset” z serwisu Kaggle [22]. W odróżnieniu od innych zbiorów danych, skupia się na czerwonych krwinkach. Baza jest bardzo obszerna i zawiera 27558 obrazów pojedynczych komórek. Dane zostały podzielone na dwie klasy: komórki zakażone zarodźcem malarii (parasitized) oraz zdrowe krwinki (uninfected). Zbiór jest popularny w testowaniu i trenowania głębokich sieci splotowych z powodu widocznych różnic między dwiema klasami.



(a) Erytrocyt zakażony zarodźcem malarii **(b)** Prawidłowy, zdrowy erytrocyt

Rys. 3.5. Przykładowe obrazy krwinek czerwonych ze zbioru *Malaria Cell Images Dataset*. Źródło: [22]

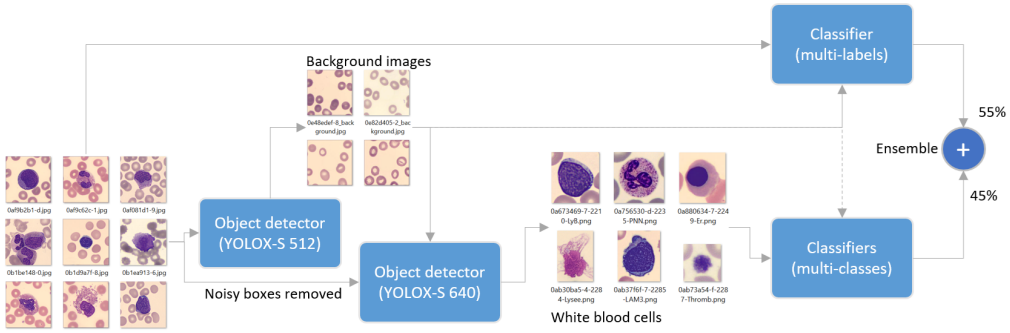
3.6. Przegląd podobnych rozwiązań z portalu GitHub

Pierwszym z analizowanych rozwiązań jest projekt ”Automated-Leukemia-Detection-using-YOLO--based-Blood-Cell-Analysis” [23]. W dokumentacji repozytorium wskazano, że jest to aplikacja w języku Python zaprojektowana w celu zliczania komórek krwi oraz wykrywania ostrej białaczki limfoblastycznej (ALL). W rozwiązaniu tym zastosowano augmentację na zbiorze ”White-Blood--Cell-Detection-Dataset”. Architektura początkowo wykorzystuje model YOLOv7, który służy do automatycznej identyfikacji i zliczania białych krwinek, a następnie wykorzystuje wagi modelu SAM do ekstrakcji limfocytów, które zostały zidentyfikowane. Ostatnim etapem jest klasyfikacja sprawdzająca, czy wyekstrahowana komórka jest prawidłowa, czy nie.

Kolejnym analizowanym rozwiązaniem jest repozytorium ”Blood-Cell-Object-Detection-using--YOLO-V8” [24]. Głównym celem tej aplikacji jest identyfikacja białych krwinek (WBC) oraz czerwonych krwinek (RBC), co ma za zadanie wspomagać identyfikację chorób układu krwiotwórczego. Głównym celem badawczym autora było porównanie dokładności i wydajności pomiędzy architekturą YOLO a sieciami z rodziny R-CNN. W projekcie, który był realizowany w Jupyter Notebook użyto zbioru danych z platformy Kaggle. W procesie uczenia modelu zastosowano technikę uczenia transferowego, która pozwala na dostrojenie do nowego zbioru wstępnie wytrenowanego modelu YOLOv8m. Oprócz tego, podczas procesu trenowania YOLO automatycznie stosuje augmentację, co zdecydowanie powiększa bazę oraz zwiększa odporność modelu na zróżnicowane dane wejściowe. W podsumowaniu autor zauważył, że architektura YOLO jest znacznie szybsza od metod typu R-CNN, ale za to mniej dokładna. Z kolei problem niższej precyzji jest skutecznie niwelowany przez nowe wersje YOLO.

Trzecim analizowanym rozwiązaniem jest projekt ”Cytologia” [25], które jest oficjalnym repozytorium międzynarodowego konkursu ”CytologIA Data Challenge”. Celem konkursu było zautomatyzowanie detekcji i klasyfikacji leukocytów na obrazach rozmazów krwi, co przyciągnęło aż 245 uczestników oraz 1958 zgłoszeń. Wyzwanie opierało się na ogromnym zbiorze 69 000 obrazów o 23 klasach krwinek białych, zarówno prawidłowych jak i patologicznych. Repozytorium to udostępnia kody trzech najlepszych rozwiązań,które podzieliły między sobą pulę nagród w wysokości 25 tysięcy euro.

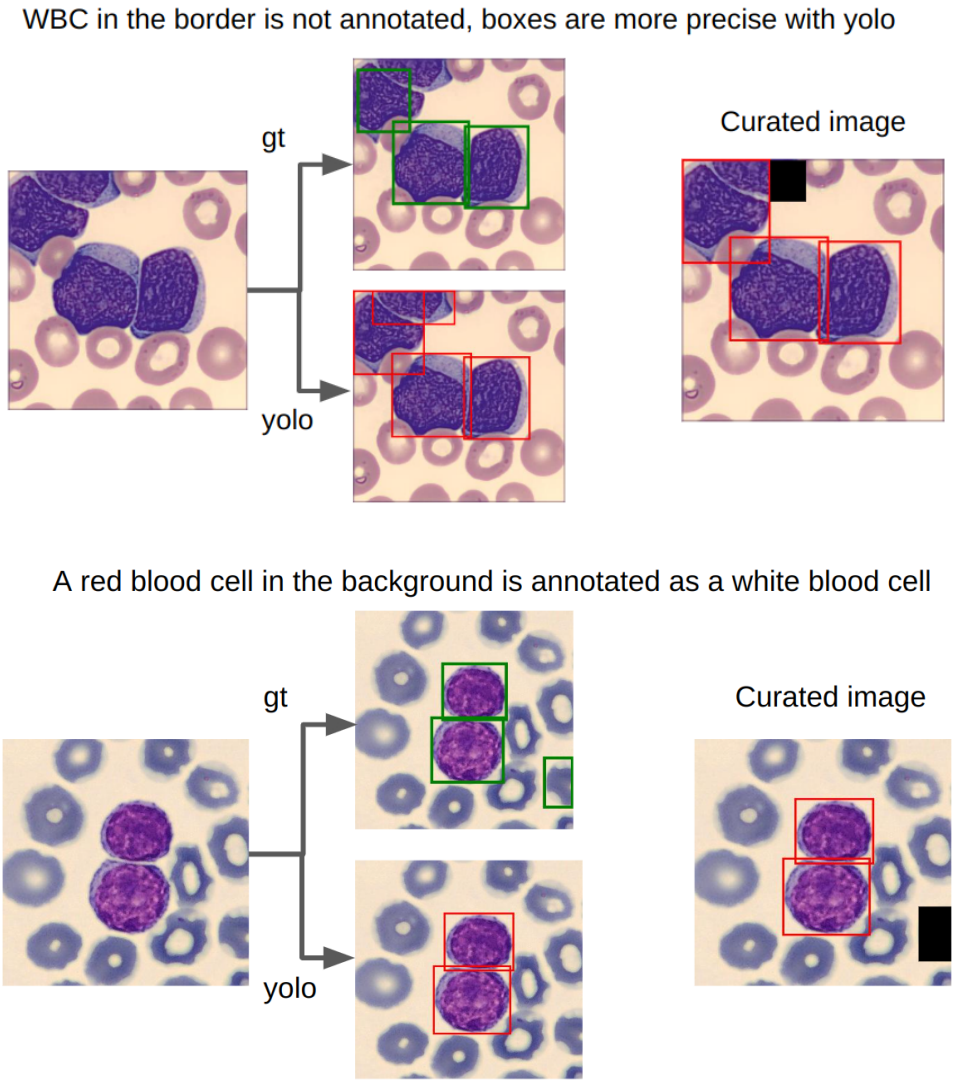
Pierwsze miejsce zajął zespół MPWARE-TEAM [26], który zaproponował rozwiązanie kaskadowego, dwuetapowego przetwarzania zobrazowanego na rysunku 3.6. W pierwszej fazie program korzysta z modeli detekcyjnych YOLOX do lokalizacji białych krwinek oraz filtracji OTSU do generowania obrazów tła. Następnie wyekstrahowane komórki trafiają do klasyfikatora, który uśrednia wyniki z różnych sieci, łączących modele splotowe oraz transformatory. Kluczem do najwyższego wyniku było nie tylko zróżnicowanie modeli, ale również zastosowanie różnych metod augmentacji.



Rys. 3.6. Schemat zwycięskiego, dwuetapowego potoku przetwarzania zaproponowany przez zespół MPWA-RE-TEAM dla wyzwania CytologIA (źródło: opracowanie własne na podstawie [26])

Drugie miejsce w tym wyzwaniu zajął projekt udostępniony przez Xueer Chen [27]. Rozwiązanie to również opiera się na uśrednianiu predykcji, jednak w tym przypadku autorka wykorzystała jedynie architektury YOLO zarówno do detekcji, jak i klasyfikacji. W procesie uczenia wykorzystano miarę IoU w celu optymalizowania ramek otaczających. Etap klasyfikacji to samodzielnie zaimplementowana przez autorkę klasa trenująca przy pomocy funkcji straty Focal Loss.

Ostatnie miejsce na podium zajął projekt Team VitaDX [28]. W przeciwieństwie do poprzednich rozwiązań, autorzy zdecydowali się na wykorzystanie modeli jednoprzebiegowych w celu skrócenia czasu wnioskowania, jednocześnie zachowując wysoką precyzję. Rozwiązanie opiera się na uśrednianiu wyników z siedmiu zróżnicowanych modeli opartych na architekturach YOLOv11 oraz YOLOv10. Kluczowym elementem było wprowadzenie zautomatyzowanego algorytmu czyszczenia i kuracji zbioru danych, co przedstawia rysunek 3.7. Polega to na poprawianiu niedokładnych ramek otaczających, a także nakładaniu czarnych masek na komórki niewykryte lub źle zaadnotowane.



Rys. 3.7. Zautomatyzowany proces kuracji danych wprowadzony przez zespół Team VitaDX. U góry: nakładanie maski na niezaadnotowaną komórkę na brzegu obrazu. Na dole: nakładanie maski na błędnie zaadnotowaną komórkę (źródło: [28]).

4. CZĘŚĆ EKSPERYMENTALNA

5. MATERIAŁY I METODY

5.1. Zbiór danych

...

5.2. Architektura zastosowanych modeli

...

5.3. Proces uczenia

...

5.4. Środowisko implementacyjne i narzędzia programistyczne

...

5.5. Metryki ewaluacyjne

6. WYNIKI

7. DYSKUSJA I PODSUMOWANIE

BIBLIOGRAFIA

[1] A. S. Adewoyin and B. Nwogoh. Peripheral blood film - a review. *Annals of Ibadan Postgraduate Medicine*, 2015. https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4415389/.

[2] R. B. Hegde, K. Prasad, H. Hebbar, and I. Sandhya. Peripheral blood smear analysis using image processing approach for diagnostic purposes: A review. *Biocybernetics and Biomedical Engineering*, 2018. https://doi.org/10.1016/j.bbe.2018.03.002.

[3] Xin Tian, Xudong Ma, Tianqi Yang, Alin Achim, Bartłomiej W. Papież, Phandee Watanaboonyongcharoen, and Nantheera Anantrasirichai. WBCBench 2026: A challenge for robust white blood cell classification under class imbalance and domain shift. In *2026 IEEE International Symposium on Biomedical Imaging (ISBI)*. IEEE, 2026. URL https://xudong-ma.github.io/WBCBench2026-Robust-White-Blood-Cell-Classification/.

[4] Luu Le, Hoang-Loc Cao, Ha-Hieu Pham, Thanh-Huy Nguyen, and Ulas Bagci. Robust white blood cell classification with stain-normalized decoupled learning and ensembling, 2026. URL https://arxiv.org/abs/2603.01976.

[5] Fan Xiao, Zirui Chen, Jilan Xu, and Junlin Hou. Foundation model enhanced hierarchical learning for white blood cell classification. In *2026 IEEE 23rd International Symposium on Biomedical Imaging (ISBI)*, pages 1–4, 2026. doi: 10.1109/ISBI61048.2026.11515411.

[6] Siddharth Srivastava, Adam Smith, Scott Brooks, Jack Bacon, and Till Bretschneider. Ensemble of small classifiers for imbalanced white blood cell classification. In *2026 IEEE 23rd International Symposium on Biomedical Imaging (ISBI)*, pages 1–5, 2026. doi: 10.1109/ISBI61048.2026.11515933.

[7] F. O. K. Rakhmonalieva, T. A. Tagne Poupi, and H.-C. Kim. A review of deep learning techniques for leukemia cancer classification based on blood smear images. *Applied Biosciences*, 2025. https://doi.org/10.3390/applbiosci4010009.

[8] S. Kasim, S. Malek, J. Tang, X. N. Kiew, et al. Multiclass leukemia cell classification using hybrid deep learning and machine learning with cnn-based feature extraction. *Scientific Reports*, 2025. https://www.nature.com/articles/s41598-025-05585-x.

[9] M. Abou Ali, F. Dornaika, and I. Arganda-Carreras. White blood cell classification: Convolutional neural network (cnn) and vision transformer (vit) under medical microscope. *Algorithms*, 2023. https://doi.org/10.3390/a16110525.

[10] J. C. Kiran, B. Naseeba, A. S. Sathwik, T. P. B. Reddy, K. Lokesh, T. B. T. Reddy, and N. P. Challa. White blood cells classification using cnn. *EAI Endorsed Transactions on Pervasive Health and Technology*, 2024. https://doi.org/10.4108/eetpht.9.4852.

[11] R. Asghar, S. Kumar, A. Shaukat, and P. Hynds. Classification of white blood cells (leucocytes) from blood smear imagery using machine and deep learning models: A global scoping review. *PLoS ONE*, 2024. https://doi.org/10.1371/journal.pone.0292026.

[12] V. Anand, S. Gupta, D. Koundal, W. Y. Alghamdi, and B. M. Alsharbi. Deep learning-based image annotation for leukocyte segmentation and classification of blood cell morphology.

BMC Medical Imaging, 2024. https://doi.org/10.1186/s12880-024-01254-z.

[13] A. T. Sahlol, P. Kollmannsberger, and A. A. Ewees. Efficient classification of white blood cell leukemia with improved swarm optimization of deep features. *Scientific Reports*, 2020. https://doi.org/10.1038/s41598-020-59215-9.

[14] Siddharth Srivastava, Adam Smith, Scott Brooks, Jack Bacon, and Till Bretschneider. Ensemble of small classifiers for imbalanced white blood cell classification: Source code. https://gitlab.com/siddharthsrivastava/wbc-bench-2026, 2026.

[15] Luu Le, Hoang-Loc Cao, Ha-Hieu Pham, and Thanh-Huy Nguyen. Robust white blood cell classification with stain-normalized decoupled learning and ensembling: Source code. https://github.com/luulecmg/WBCBench2026, 2026.

[16] Sumith Singh Kothwal. Blood cell images for cancer detection, 2025. URL https://www.kaggle.com/dsv/10500753.

[17] Paul Mooney. Blood cell images: 12,500 images of 4 different cell types, 2018. URL https://www.kaggle.com/datasets/paultimothymooney/blood-cells. Rozszerzony zestaw danych oparty na repozytorium BCCD.

[18] Shenggan. Bccd_dataset: Blood cell count and detection dataset, 2017. URL https://github.com/Shenggan/BCCD_Dataset.

[19] Shafiullah Shafin. C-nmc 2019 dataset, 2024. URL https://www.kaggle.com/datasets/shafiullahshafin/c-nmc-2019-dataset.

[20] Andrea Acevedo, Anna Merino, Santiago Alférez, Ángel Molina, Laura Boldú, and José Rodellar. A dataset for microscopic peripheral blood cell images for development of automatic recognition systems, 2020. URL https://data.mendeley.com/datasets/snkd93bnjr/1.

[21] Andrea Acevedo, Santiago Alférez, Anna Merino, Laura Puigví, and José Rodellar. Recognition of peripheral blood cell images using convolutional neural networks. *Computer Methods and Programs in Biomedicine*, 180:105020, 2019. URL https://www.sciencedirect.com/science/article/abs/pii/S0169260719303578.

[22] Sivaramakrishnan Rajaraman, Sameer Antani, Mahdieh Poostchi, and Kamolrat Silamut. Malaria cell images dataset, 2018. URL https://www.kaggle.com/datasets/iarunava/cell-images-for-detecting-malaria.

[23] Brahim Mohamed Amine. Automated leukemia detection using yolo--based blood cell analysis, 2023. URL https://github.com/medmabcf/Automated-Leukemia-Detection-using-YOLO-based-Blood-Cell-Analysis. Udostępnione repozytorium w serwisie GitHub, konto: medmabcf.

[24] angelmacwan. Blood cell object detection using yolo-v8, 2024. URL https://github.com/angelmacwan/Blood-Cell-Object-Detection-using-YOLO-V8. Udostępnione repozytorium w serwisie GitHub, konto: angelmacwan.

[25] Trustii-team. Cytologia: Result of the cytologia data challenge, 2025. URL https://github.com/Trustii-team/Cytologia.

[26] MPWARE-TEAM. Cytologia - white blood cells detection (1st place), 2025. URL https://github.com/MPWARE-TEAM/Cytologia.

[27] Xueer Chen. Cytologia 2nd place solution, 2025. URL https://github.com/xueerchen1990/cytologia_2nd_place.

[28] Simon Thomine. Cytologia 3rd place solution, 2025. URL https://github.com/SimonThomine/Cytologia-Data-Challenge.

WYKAZ RYSUNKÓW

2.1. Taksonomia metod głębokiego uczenia oraz etapów przetwarzania danych w diagnostyce białaczki. Źródło: [7] 13
2.2. Cechy morfologiczne: (a) zdrowych leukocytów, (b) limfoblastów i (c) mieloblastów, wykorzystywane do trenowania i oceny modelu. Źródło: [8] 14
2.3. Dane rozszerzone przy użyciu technik augmentacji (rotacje i odbicia lustrzane) wykorzystane w procesie treningowym modelu. Źródło: [8] 14
2.4. Schemat blokowy hybrydowego systemu klasyfikacji obrazów białaczki łączącego sieć VGG19 z algorytmem optymalizacji SESSA. Źródło: [13] 19
2.5. Przykładowe obrazy 13 klas białych krwinek z odgórnie narzuconego zbioru danych w wyzwaniu WBCBench2026: (A) neutrofil segmentowany, (B) limfocyt, (C) monocyt, (D) komórka blastyczna, (E) eozynofil, (F) neutrofil pałeczkowaty, (G) mielocyt, (H) metamielocyt, (I) limfocyt atypowy, (J) bazofil, (K) promielocyt, (L) komórka plazmatyczna, (M) prolimfocyt [3]. 20

3.1. Przykładowe obrazy komórek z bazy danych z podziałem na pięć klas. Źródło: [16] 22
3.2. Przykładowe obrazy komórek ze zbioru *Blood Cell Images* (BCCD) reprezentujące cztery różne klasy morfologiczne białych krwinek: eozynofil, limfocyt, monocyt oraz neutrofil. Źródło:[17] 22
3.3. Porównanie próbek z bazy C-NMC 2019. Źródło: [19] 23
3.4. Przykładowe obrazy ośmiu klas morfologicznych krwinek ze zbioru *Peripheral Blood Cell* (PBC). Źródło: [20, 21] 24
3.5. Przykładowe obrazy krwinek czerwonych ze zbioru *Malaria Cell Images Dataset*. Źródło: [22] 24
3.6. Schemat zwycięskiego, dwuetapowego potoku przetwarzania zaproponowany przez zespół MPWARE-TEAM dla wyzwania CytologIA (źródło: opracowanie własne na podstawie [26]) 26
3.7. Zautomatyzowany proces kuracji danych wprowadzony przez zespół Team VitaDX. U góry: nakładanie maski na niezaadnotowaną komórkę na brzegu obrazu. Na dole: nakładanie maski na błędnie zaadnotowaną komórkę (źródło: [28]). 27

WYKAZ TABEL

A. DODATEK A